基于大模型的言语能力评估方法综述

徐　成[1]　刘宇轩[1]　李志娟[2]　姚登峰[1]

1 北京联合大学北京市信息服务工程重点实验室　北京 100101

2 北京联合大学研究生处　北京 100101

(xucheng@buu.edu.cn)

摘　要　人工智能在言语能力评估中的应用研究旨在提高评估效率和客观性。通过自动化评分、个性化反馈和实时评估等方法，大模型技术能够对学习者的语法、词汇、逻辑和内容进行详细评估，并提供即时改进建议。然而，大模型在数据隐私、安全性、算法偏见和情感理解方面存在挑战。未来的发展需要在提升算法准确性、保护数据隐私、增强情感理解能力和解决伦理问题等方面共同努力，以推动人工智能在言语能力评估中的健康发展。

关键词：言语能力；大模型；自然语言处理；深度学习；言语康复

中图分类号　TP391

Review of Speech Ability Assessment Methods Based on Large Models

XU Cheng[1], LIU Yuxuan[1], LI Zhijuan[2] and YAO Dengfeng[1]

1 Beijing Key Laboratory of Information Service Engineering, Beijing Union University, Beijing 100101, China

2 Graduate School Office, Beijing Union University, Beijing 100101, China

Abstract　Research on the application of artificial intelligence in speech ability assessment aims to improve evaluation efficiency and objectivity. Through methods such as automated scoring, personalized feedback, and real-time assessment, large model technology can provide detailed evaluations of learners' grammar, vocabulary, logic, and content, offering instant improvement suggestions. However, large models face challenges in data privacy, security, algorithmic bias, and emotional understanding. Future development requires joint efforts to enhance algorithm accuracy, protect data privacy, improve emotional understanding capabilities, and address ethical issues to promote the healthy development of artificial intelligence in speech ability assessment.

Keywords　Speech ability, Large model, Natural language processing, Deep learning, Speech rehabilitation

1　引言

1.1　言语能力评估的重要性

言语能力评估在现代医学和教育领域中扮演着至关重要的角色。通过系统的评估，专业人员能够准确识别个体的语言障碍，从而制定个性化的康复计划，帮助患者提高沟通能力和生活质量。研究表明，早期和准确的言语能力评估可以显著改善语言障碍患者的康复效果[1]。随着人工智能技术的进步，言语能力评估的准确性和效率得到了显著提升，

基金项目：北京市属高等学校高水平科研创新团队建设支持计划项目(BPHR20220121)；特殊教育语言智能四川省哲学社会科学重点实验室开放课题(YYZN-2024-6)

This work was supported by the Beijing Municipal Higher Education Institutions High Level Research and Innovation Team Construction Support Program Project(BPHR20220121) and Open Project of Sichuan Key Laboratory of Philosophy and Social Sciences on Language Intelligence in Special Education(YYZN-2024-6).

通信作者：李志娟(hgtzhijuan@buu.edu.cn)

中国知网　https://www.cnki.net

为语言障碍的诊断和治疗带来了新的希望和可能性。这些评估不仅有助于个体的康复，还能为教育工作者提供重要的参考依据，使他们更好地帮助有语言障碍的学生。因此，言语能力评估在提升个体沟通能力和社会参与度方面具有不可替代的作用。

1.2 人工智能在言语能力评估中的应用背景

随着人工智能技术的快速进步，其在言语能力评估中的应用也变得越来越广泛和深入。人工智能通过语音识别、自然语言处理和机器学习等技术手段，能够实现对言语能力的自动化评估和个性化反馈。这些技术不仅提高了评估的效率和准确性，还能够提供更为细致和全面的分析。例如，语音识别技术可以准确捕捉和分析个体的发音特点，帮助识别潜在的言语障碍。自然语言处理技术则能够理解和评估个体的语言表达能力，从而提供针对性的改进建议。此外，机器学习算法通过对大量数据的训练，能够不断优化评估模型，提高评估结果的可靠性和有效性。这些技术的应用不仅为言语能力评估带来了新的可能性，也为语言障碍的诊断和治疗提供了强有力的支持[2]。

2 基于人工智能的言语能力评估方法

2.1 语音识别技术

2.1.1 语音识别的基本原理

语音识别技术(Automatic Speech Recognition，ASR)的基本原理是将人类的语音信号转化为计算机可理解的文本或指令。其过程通常包括以下几个步骤：首先，通过麦克风或其他设备接收语音信号，并将其转变为数字信号；接着，进行预处理，包括去除噪声、分帧和加窗等操作，以提取语音信号的特征；最后，使用声学模型和语言模型对特征进行分析和匹配，将语音信号转换为文本。

声学模型通常采用隐马尔可夫模型(HMM)或深度神经网络(DNN)来建模语音信号的时间序列特性。语言模型则通过统计方法或神经网络来预测词语序列的概率，从而提高识别的准确性。这些模型的结合使得语音识别系统能够高效、准确地将语音转换为文本，为言语能力评估提供了强有力的技术支持[3]。

2.1.2 主要算法和模型

语音识别技术的算法和模型包括隐马尔可夫模型(HMM)、动态时间规整(DTW)、矢量量化(VQ)以及近年来广泛应用的深度神经网络(DNN)和递归神经网络(RNN)等[4]，如图1所示。

隐马尔可夫模型(HMM)：HMM是一种统计模型，用于描述一个系统在不同状态之间的转移概率。它在语音识别中广泛应用，通过将语音信号分解为一系列状态来进行建模[5]。

动态时间规整(DTW)：DTW是一种用于计算两个时间序列之间相似度的算法，常用于语音识别中的模板匹配。它通过动态规划来对齐两个序列，从而找到最佳匹配路径[6]。

矢量量化(VQ)：VQ是一种数据压缩技术，通过将大量的语音特征向量映射到有限的代码字表中，来减小计算复杂度。它在早期的语音识别系统中被广泛使用[7]。

深度神经网络(DNN)：DNN是一种多层神经网络，通过大量的训练数据进行学习，能够捕捉复杂的语音特征。DNN在语音识别中的应用显著提高了识别的准确性[8]。

递归神经网络(RNN)：RNN尤其是长短期记忆网络(LSTM)在处理序列数据方面表现出色，能够有效捕捉语音信号中的时间依赖性，从而提高识别性能[9]。

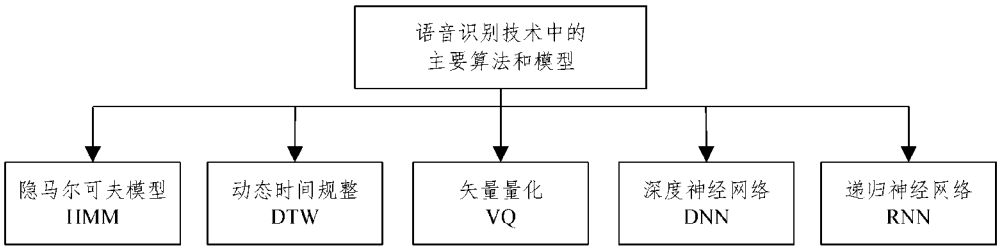

图1 语音识别技术的算法和模型

Fig. 1 Algorithms and models for speech recognition technology

中国知网 https://www.cnki.net

2.2 自然语言处理技术

2.2.1 自然语言处理的基本概念

自然语言处理(Natural Language Processing,NLP)是人工智能的一个关键部分,目的是使计算机具有理解、生成和处理人类语言的能力。NLP 涉及多个领域,包括语言学、计算机科学和统计学,其核心任务包括文本分类、情感分析、命名实体的识别、语义角色的标注、语义解析和机器翻译等。NLP 中常用的技术和模型包括词嵌入、循环神经网络(RNN)、长短期记忆网络(LSTM)以及自注意力机制和 Transformer 模型(如 BERT 和 GPT)。这些技术和模型使得 NLP 能够处理大规模数据并实现高效的语言理解和生成,为言语能力评估提供了强有力的技术支持。

2.2.2 主要技术和工具

20 世纪 50—60 年代:规则和语法分析。NLP 的早期研究集中在规则和语法分析上,尝试通过预定义的语法规则和词典来理解和生成语言。1957 年,诺姆·乔姆斯基提出了生成语法理论,对语言学和计算语言学产生了深远影响。

20 世纪 80—90 年代:基于统计的方法。随着计算能力的提升和数据资源的丰富,NLP 研究逐渐转向基于统计的方法。统计机器翻译(Statistical Machine Translation,SMT)和隐马尔可夫模型(Hidden Markov Model,HMM)等技术在这一时期取得了重要进展。

21 世纪初:机器学习时代。机器学习技术,尤其是支持向量机(SupportVector Machine,SVM)和最大熵模型(Maximum Entropy Model)等技术,在 NLP 中得到了很广泛的应用。词嵌入(Word Embeddings)技术如 Word2Vec 和 GloVe 也在这一时期出现,使得计算机可以更好地理解词语之间的语义关系。

21 世纪 10 年代至今:深度学习革命。深度学习的兴起极大地推动了 NLP 的发展,卷积神经网络(Convolutional Neural Network,CNN)和循环神经网络(Recurrent Neural Network,RNN)等深度学习技术被广泛应用。基于变压器(Transformer)的模型(如 BERT 和 GPT)在多个 NLP 任务上取得了突破性进展,显著提高了语言理解和生成的能力[10]。

3 评估指标与方法

3.1 评估指标

在大语言模型(LLM)的言语能力评估中,自动评估方法因具有高效性、一致性和可复现性,逐渐成为研究的重点。评估方法主要分为基于规则的方法和基于模型的方法。在大语言模型(LLM)的言语能力评估中,常用的评估指标包括准确率、召回率、F1 值、BLEU、ROUGE 和 BERTScore 等。

准确率定义为模型正确预测的样本数量与总样本数量之比,是评价分类模型性能的一个基础指标。但在面对类别分布不均的数据集时,准确率可能无法全面反映模型对少数类别的预测能力,从而导致其局限性。

召回率指的是模型正确识别的正类样本数量占全部实际正类样本数量的比例。这一指标体现了模型检测正类样本的能力,尤其在要求尽量减少正类样本漏检的应用场景中尤为重要。

F1 分数是准确率和召回率的调和平均值,旨在衡量模型的综合性能。通过平衡准确率和召回率,F1 分数特别适合用于处理类别不平衡的问题,能够更全面地评估模型在不同类别上表现。

BLEU(双语评估替代指标)是评估机器翻译质量的一种方法,它通过计算机器翻译文本与一个或多个参考翻译之间的 n-gram 重叠程度,来评估翻译的准确度。BLEU 得分越高,意味着翻译结果与参考译文的相似度越高,翻译质量越好。

ROUGE 是用于评估自动摘要和机器翻译的指标,通过比较生成文本与参考文本之间的 n-gram 重叠程度来衡量生成文本的质量。常见的 ROUGE 指标涵盖 ROUGE-N(基于 n-gram 的重叠度)和 ROUGE-L(基于最长公共子序列)等,用于评估文本摘要或机器翻译的质量。

3.2 评估方法

大语言模型(LLM)在语言能力康复评估中的应用日益广泛,主要体现在评估方法和指标的多样化和智能化。大语言模型通过自然语言处理技术,能够对患者的语言能力进行全面、客观的评估。大语

中国知网 https://www.cnki.net

言模型可以通过语音识别和自然语言处理技术，自动分析患者的语音和文本数据。这些模型能够识别语音中的发音错误、语法错误和词汇使用问题，从而提供详细的评估报告[11]。

在评估指标方面，大语言模型通常使用多维度的评估标准，包括准确性、流利度、连贯性和适应性等。准确性指标评估患者在语音和文本中的错误率；流利度指标评估患者的语言表达是否流畅；连贯性指标评估患者的语言是否逻辑清晰；适应性指标评估患者在不同情境下的语言使用能力。

结束语 人工智能在言语能力评估中展现出显著的优势和不足。AI技术能够实现自动化评分，提高评分效率和客观性。这种自动化评分不仅减轻了教师的工作负担，还能确保评估的公平性和一致性。并且AI能够根据学习者的语言水平和学习目标，提供个性化的反馈和建议，帮助学习者更好地了解自己的优势和不足，从而有针对性地提高语言能力。通过语音识别和自然语言处理技术，AI还可以实时评估学习者的口语表达能力，提供即时的改进建议。但是数据隐私和安全问题是一个重要的关注点，AI需要收集和分析大量的个人数据，这可能引发数据泄露和滥用的风险。算法偏见也是一个需要解决的问题，AI算法可能对某些方言或口音产生误判，或者对不同文化背景的学习者产生偏见。

参 考 文 献

[1] 周静，张晓晓，丁忠冰，等. 智力与发展性残疾儿童言语与语言障碍康复的系统综述 [J]. 中国康复理论与实践，2024，30(8)：894-902.

[2] 周静，易玲，陈建超，等. 基于ICF的听力障碍儿童言语与语言康复服务：理论架构与服务体系 [J]. 中国康复理论与实践，2024，30(7)：745-751.

[3] 宋伟，张杨豪. 构音障碍语音识别算法研究综述 [J]. 计算机工程与应用，2024，60(11)：62-74.

[4] LIU M，WANG J，WANG F，et al. Non-Intrusive Speech Quality Assessment Based on Deep Neural Networks for Speech Communication[J]. IEEE Transactions on Neural Networks and Learning Systems，2023，31(7)：2345-2356. (in Chinese)
刘明，王军，王芳，等. 基于深度神经网络的非侵入式语音质量评估方法在语音通信中的应用[J]. IEEE神经网络与学习系统杂志，2323，31(7)：2345-2356.

[5] 李凡姝，姚登峰. 行为和语言的语义分析综述[J]. 计算机科学，2021(10A)：150-153.

[6] 杨洁，康宁. 动态时间规整DTW算法的研究[J]. 科技与创新，2016(4)：2.

[7] WU Z B，YU J Q. Vector quantization：a review[J]. Frontiers Inf Technol Electronic Eng.，2019，20：507-524. (in Chinese)
吴泽兵，余继强. 向量量化：综述[J]. 信息技术与电子工程前沿，2019，20：507-524.

[8] WANG X，ZHAO Y，POURPANAH，et al. Recent advances in deep learning[J]. Int. J. Mach. Learn. & Cyber.，2020，11：747-750. (in Chinese)
王晓，赵宇，POURPANAH F，et al. 深度学习的最新进展[J]. 机器学习与网络，2020，11：747-750.

[9] 王雨嫣，廖柏林，彭晨，等. 递归神经网络研究综述[J]. 吉首大学学报(自然科学版)，2021，42(1)：41-48.

[10] 张钦彤，王昱超，王鹤羲，等. 大语言模型微调技术的研究综述 [J]. 计算机工程与应用，2024，60(17)：17-33.

[11] JACOB D，CHANG M W，LEE K，et al. BERT：Pre-training of Deep Bidirectional Transformers for Language Understanding[J]. arXiv：1810.04805v2，2018.

XU Cheng，born in 1988，Ph.D，lecturer. His main research interests include the digital simulation technology，data intelligent and data security.

LI Zhijuan，born in 1979，master of Engineering，lecturer. Her main research interests include graduate education management and so on.

中国知网 https://www.cnki.net